

인공신경망과 딥러닝 최종 프로젝트

Vision Transformers need registers (2024,ICLR)

7팀

김연수 - 25532003

오은정 - 25622006

추현빈 - 25512092



Contents

- Overview
- Problem Formulation
- Re-Production experiments
- Conclusion
- Contribution
- Appendix

Overview – Motivation & Problem

Vision Transformer의 성공


- ViT는 다양한 representation learning의 backbone
 - DeiT-III(Supervised)
 - OpenCLIP(Vision-Language)
 - DINOv1/v2(Self-Supervised)

ViT에서 발견된 문제점

- Observation
 - High-norm outlier token 발생, Attention map에 artifact 생성
- Consequence
 - Local feature 정보 손실, Object discovery 성능 저하

Key Question

- ◆ 왜 ViT는 이러한 High-norm artifact token들을 생성하는가?



Artifacts observed in attention maps (DeiT-III, OpenCLIP, DINO)

Overview – Proposed Method

Core Insight


- 정보량이 적은 patch token을 내부 계산용 공간으로 재활용
 - Background 영역의 patch token을 사용
 - Local information 감소, Global information 저장

Proposed Method

- Register token
 - ViT가 계산 중 활용할 수 있는 별도의 learnable token 추가

Expected Effect

- Patch token은 local feature 유지
- Register token이 전체 이미지 정보를 대신 저장
- Attention artifact 제거



Problem Formulation – Inference analysis

Artifact Detection




- High-norm outlier token의 존재 여부

Feature Analysis

- Bimodal norm distribution 확인

Token Behavior Analysis

- Neighbor cosine similarity 분석
- Outlier token의 local/global information 특성 확인



(a) Cosine similarity to neighbors.

	position prediction		reconstruction
	top-1 acc	avg. distance ↓	L2 error ↓
normal	41.7	0.79	18.38
outlier	22.8	5.09	25.23

(b) Linear probing for local information.

Artifact 토큰과 normal 토큰의 주변 patch와의 cos 유사도 비교


	IN1k	P205	Airc.	CF10	CF100	CUB	Cal101	Cars	DTD	Flow.	Food	Pets	SUN	VOC
[CLS]	86.0	66.4	87.3	99.4	94.5	91.3	<u>96.9</u>	91.5	85.2	99.7	94.7	96.9	78.6	<u>89.1</u>
normal	65.8	53.1	17.1	97.1	81.3	18.6	73.2	10.8	63.1	59.5	74.2	47.8	37.7	70.8
outlier	<u>69.0</u>	<u>55.1</u>	<u>79.1</u>	<u>99.3</u>	<u>93.7</u>	<u>84.9</u>	97.6	<u>85.2</u>	<u>84.9</u>	<u>99.6</u>	<u>93.5</u>	<u>94.1</u>	<u>78.5</u>	89.7

Outlier token과 normal token의 image classification 성능 비교

Problem Formulation – Register Validation

Register token의 효과 검증


- Before Register
 - High-norm outlier token 발생
 - Attention map artifact 존재
- After Register
 - Outlier token 감소
 - Attention map 개선




Register token 존재 여부에 따른 attention map

Artifact Emergence Analysis


- Artifact가 언제 발생하는가?
 - 레이어 중간쯤부터 발생하는가?
 - 학습의 1/3 지점부터 발생하는가?
 - 큰 모델에서 발생하는가?



(a) Norms along layers.



(b) Norms along iterations.



(c) Norms across model size.

학습 중 artifact 발현 시점 및 조건

Problem Formulation – Downstream Evaluation

Evaluation Protocol

- DINOv2와 DINOv2 + Register 비교
- Register token이 downstream task에 미치는 영향 분석

Evaluation Tasks

- ImageNet Classification(Top-1 Accuracy)
- ADE20K Semantic Segmentation(mIoU)
- NYUd Depth Estimation(RMSE)

Key Findings

- DINOv2 + Register가 모든 평가에서 우수한 성능 달성

	ImageNet Top-1	ADE20k mIoU	NYUd rmse ↓
DeiT-III	84.7	38.9	0.511
DeiT-III+reg	84.7	39.1	0.512
OpenCLIP	78.2	26.6	0.702
OpenCLIP+reg	78.1	26.7	0.661
DINOv2	84.3	46.6	0.378
DINOv2+reg	84.8	47.9	0.366

DINOv2와 DINOv2+Register의 downstream task 성능 비교

Re-Production experiments – Target Experiments


Experiments

- Artifact Detection
 - High-norm outlier token
 - Model scale: DINOv2 / SigLIP
- Artifact Characterization
 - Bimodal norm distribution
 - Cos similarity
 - CLS vs Normal vs Outlier Top-1
- Register token Validation
 - Without vs With register
 - Downstream tasks

Results – Artifact Detection & Bimodal Distribution


DINOv2에서 high-norm outlier token의 존재 여부

- High-norm outlier token
 - 일부 patch token에서 비정상적으로 큰 norm 관찰
 - 논문에서 정의한 artifact와 동일한 패턴 확인



Register token 여부에 따른 norm 발현

- Bimodal Norm Distribution
 - Norm histogram이 두 개의 cluster로 분리됨
 - Threshold = 150 기준으로 outlier token 구분
 - Outlier Ratio $\approx 3.39\%$ 로 논문의 2.37% 와 근사



Register token 여부에 따른 norm의 분포

Results – Linear Probing

Outlier token과 normal token의 image classification 성능 비교

Metric	CIFAR10	CIFAR100	Food101	CUB200	Aircraft	Caltech101	Flowers102	Pets	DTD
CLS	99.46	93.95	94.81	91.28	87.25	<u>93.31</u>	99.69	96.59	<u>81.81</u>
Normal	97.42	82.16	76.42	19.58	18.83	74.24	61.60	50.59	58.48
Outlier	<u>99.23</u>	<u>92.70</u>	<u>92.90</u>	<u>84.62</u>	<u>74.66</u>	96.36	<u>99.60</u>	<u>93.96</u>	83.28

Linear probing accuracy (%) on 9 transfer benchmarks.

Setting (detailed setup은 appendix 참조)

- Model: DINOv2 ViT-G/14
- Outlier: patch token L2 norm > 150
- Feature:
 - CLS: CLS token output
 - Outlier: norm > 150 인 token들 중 1개 랜덤 선택
 - Normal: norm <= 150 인 token들 중 1개 랜덤 선택
- Linear Probe: frozen feature 위 linear classifier 학습 (Kornblith et al. 2019 프로토콜)
- Datasets: 9개 transfer benchmark (CIFAR10/100, Food101, CUB200, Aircraft, Caltech101, Flowers102, Pets, DTD)

Results – Linear Probing

Outlier token과 normal token의 image classification 성능 비교

Metric	CIFAR10	CIFAR100	Food101	CUB200	Aircraft	Caltech101	Flowers102	Pets	DTD
CLS	99.46	93.95	94.81	91.28	87.25	<u>93.31</u>	99.69	96.59	<u>81.81</u>
Normal	97.42	82.16	76.42	19.58	18.83	74.24	61.60	50.59	58.48
Outlier	<u>99.23</u>	<u>92.70</u>	<u>92.90</u>	<u>84.62</u>	<u>74.66</u>	96.36	<u>99.60</u>	<u>93.96</u>	83.28

Linear probing accuracy (%) on 9 transfer benchmarks.

Key findings

- Normal patch 는 linear probing 성능이 CLS 에 비해 현저히 낮으며, 각 개별 patch는 global information 을 담고 있다고 보기 힘들.
- 반면 outlier patch는 CLS와 거의 동등한 분류 성능을 달성
- **Outlier가 이미지 전체의 global information 를 저장하는 “임시 메모리” 역할을 한다는 가설의 직접적인 증거**

Results – Cosine similarity


Outlier token에서 주변 patch와의 cosine similarity 비교

Setting

- Model: DINOv2 ViT-G/14(frozen)
- Outlier: patch token L2 Norm > 150
- Metric: 각 patch와 spatial 4-neighbor 간의 평균 cosine similarity (patch embedding 기준)
- 비교: outlier patch vs normal patch 의 similarity 분포

Key Findings

- mean 0.8228 (outlier) vs 0.6204 (normal)
→ Outlier patch는 normal patch에 비해 4-neighbor와의 cosine similarity가 현저히 높음
- Outlier patch의 distribution이 $\cos \text{sim} \approx 1$ 부근에 집중되어 있음
→ 시각적으로 거의 동일한 redundant 영역에 outlier가 형성됨
- “Outlier는 정보량이 낮은 patch 위치에 등장한다”는 paper의 가설을 뒷받침하는 정량적 근거



Results – Downstream Tasks

DINOv2와 DINOv2+Register의 downstream task 성능 비교

	Classification ImageNet	Segmentation ADE20k	Depth Estimation NYUd
Backbone	Top-1 Acc (%) ↑	mIoU (%) ↑	RMSE (m) ↓
DINOv2 ViT-L/14	86.40	48.96	0.4957
DINOv2 ViT-L/14 + Register	86.74	50.31	0.4711

세 downstream task에서 register 추가에 따른 성능 변화

Common Setting

- Backbone: DINOv2 ViT-L/14 (frozen, 공식 release checkpoint) – 모든 downstream task 동일
- frozen feature 위에 task 별 head를 직접 학습
- Comparison: dinov2_vitl14 vs dinov2_vitl14_reg (register 4개 추가)

※ task 별 자세한 setup은 appendix 참조

Results – Downstream Tasks

DINOv2와 DINOv2+Register의 downstream task 성능 비교

	Classification ImageNet	Segmentation ADE20k	Depth Estimation NYUd
Backbone	Top-1 Acc (%) ↑	mIoU (%) ↑	RMSE (m) ↓
DINOv2 ViT-L/14	86.40	48.96	0.4957
DINOv2 ViT-L/14 + Register	86.74	50.31	0.4711

세 downstream task에서 register 추가에 따른 성능 변화

Key findings

- Register 추가는 세 task 모두에서 성능 개선
- Patch feature를 직접 사용하는 dense prediction 에서 개선폭이 비교적 큼
- **Outlier가 patch feature를 손상시켰다는 paper 가설을 지지**

Conclusion & Discussion

Conclusion

- DINOv2에서 논문이 보고한 high-norm outlier token과 bimodal norm distribution을 재현
- Outlier token은 normal token보다 높은 분류 성능을 보이며, global information을 저장하는 경향을 확인
- Cosine similarity 분석을 통해 outlier가 정보량이 적은 redundant 영역에서 발생한다는 논문의 관찰을 재현
- Downstream task(ImageNet/ADE20k/NYUd)에서도 register 추가가 성능을 저해하지 않고 dense prediction에서 더 큰 개선을 보임을 확인

Discussion

- Outlier patch의 발생 원인에 대한 mechanism적인 설명이 부재
 - 본 논문은 outlier 가 “어디서, 언제, 무엇을 담는가”는 characterize 했으나, 왜 발생하는 지에 대한 것은 “memory로 재활용한다”라는 가설 수준
→ 후속 연구 Jiang et al. (2025), "Vision Transformers Don't Need Trained Registers"가 이를 이어받아 register neuron을 식별
- 다른 모델로의 일반화 – SigLIP에서도 동일 현상 확인
 - 본 논문에서는 DINOv2, DeiT-3, OpenCLIP에서 outlier를 보고했으나, SigLIP은 검증 대상에 없었음. SigLIP을 추가 분석한 결과, 동일한 high-norm outlier 패턴이 관찰됨.

Results – Additional Validation on SigLIP



다른 ViT-based 모델에서도 high-norm token이 관찰되는가?

- Setting

- Backbone: Official SigLIP vision encoder checkpoint 사용 (frozen)
- Feature extraction: frozen SigLIP의 final feature를 추출한 뒤, average pooling을 거쳐 image feature로 활용

- Results

- Outlier ratio: 1.01%
- DINOv2v와 유사한 Bimodal 분포 확인
- 배경에 high-norm artifact 분포 확인



SigLIP에서의 Artifact 발현 사례

Contribution

김연수

- Linear Probing (CLS / Normal / Outlier) 재현
- Register token downstream task 분석
- 발표

오은정

- Artifact Detection 구현
- Bimodal Distribution 분석
- DINO 계열 검증

추현빈

- Cosine Similarity 실험 재현
- SigLIP 추가 검증 실험
- 발표 자료 제작

Appendix

Main Paper

- [Darcet et al.] "Vision Transformers Need Registers", ICLR(2024)

Backbone Models

- [Caron et al.] "DINO: Emerging Properties in Self-Supervised Vision Transformers", ICCV(2021)
- [Oquab et al.] "DINOv2: Learning Robust Visual Features without Supervision", (2023)
- [Zhai et al.], "SigLIP: Sigmoid Loss for Language Image Pre-Training", ICCV(2023)

평가 프로토콜 참고

- [Chen et al.], "SimCLR: A Simple Framework for Contrastive Learning of Visual Representations", ICML(2020) – linear evaluation protocol
- [Kornblith et al.], "Do better ImageNet Models Transfer Better?", CVPR(2019) – transfer benchmark protocol
- [Eigen et al.], "BinsFormer: Revisiting Adaptive Bins for Monocular Depth Estimation", (2022) – depth estimation evaluation protocol

GitHub

- <https://github.com/dustnehowl/ds-dl-vision-transformer-need-registers-term-project.git>

Appendix

Linear Probing detailed setup

A. Feature Extraction

항목	값
Image Size	224 px → 16×16 = 256 patches
Patch Size	14
Embed Dim (ViT-G)	1536
Token 추출 layer	<code>x_prenorm</code> (LayerNorm 이전)
Preprocessing	Resize 256 (bicubic) → CenterCrop 224 → ImageNet normalize
Per-image sampling	조건 만족 patch 중 1개 random — outlier 없는 이미지는 해당 trial 제외
Trials	3회 (token random seed 변경) → mean ± std
Base Seed	42

B. Linear Probing Protocol

항목	값
Classifier	L2-regularized Logistic Regression (with bias)
Backend	PyTorch L-BFGS on GPU, Strong Wolfe line search
Objective	$\sum_i \text{CE}(x_i, y_i; w) +$ $(1/2C) \cdot \ w\ ^2$
Train / Val split	80 / 20 (random shuffle, seed 고정)
C Sweep	9 values, <code>logspace(-6, 2)</code> = {1e-6, 1e-5, ..., 1e1, 1e2}
Selection	val acc로 best C 선택 → full train 재 학습 → test 평가
Iterations	sweep 200 / final retrain 400
Init	weight, bias 모두 zeros
Metric	Top-1 accuracy (%)

C. Datasets (9 transfer benchmarks)

Dataset	# Classes	Train	Test
CIFAR10	10	50,000	10,000
CIFAR100	100	50,000	10,000
Food101	101	75,750	25,250
CUB200	200	5,994	5,794
Aircraft	100	6,667	3,333
Caltech101	101	30/class	나머지
Flowers102	102	2,040	6,149
Oxford-IIIT Pets	37	3,680	3,669
DTD	47	1,880	1,880

Appendix

Downstream task detailed setup

	ImageNet (Classification)	ADE20k (Segmentation)	NYUd (Depth)
Metric	Top-1 Acc (%) ↑	mIoU (%) ↑	RMSE (m) ↓
Image Size	224 px	518 px	518 px
Feature Source	last 4 blocks (CLS + avg patch)	Blocks [4,11,17,23] (patches only)	Blocks [4,11,17,23] (patches + CLS)
Feature Dim	5×D = 5120	4×D = 4096	4×2D = 8192
Head	Linear(5120→1000)	BN + <u>Conv2d</u> (4096→150)	<u>Conv2d</u> (8192→256 bins)
Loss	Cross-Entropy	Cross-Entropy	SigLoss (log-space)
Optimizer	SGD (mom=0.9, <u>wd</u> =0)	AdamW (<u>wd</u> =0)	AdamW (<u>wd</u> =0.01)
Learning Rate	0.04 (batch-scaled)	8e-4	1e-4
Schedule	cosine	cosine	30% warm-up + cosine
Training	10 epochs	20,000 iter	38,400 iter
Batch Size	1024	8	16
Augmentation	none	scale [0.5,2.0] + crop + flip	scale [0.7,1.3] + crop + flip
Dataset (train / val)	1.28M / 50K (1000-cls)	20.2K / 2K (150-cls)	47.6K / 654 (depth)

AI tool usage statement

1. 최종 artifact 관찰 코드 구현(GitHub 적용): Claude 4.7 Opus
2. Linear Probing 코드 구현: Claude 4.7 Opus
3. Downstream task 학습 코드 구현: Claude 4.7 Opus
4. GitHub 레포지토리 정리 및 README 작성: Claude 4.7 Opus
5. 4-way neighbor cosine similarity 측정: GPT 5.5
6. SigLIP artifact 관찰 코드 구현: GPT 5.5
7. DINO v1/v2 artifact 관찰 코드 구현: Claude 4.6 sonnet